

به نام آغازگر چرخه‌ی هوشمندی

1. مقدمه

یادگیری ماشین (Machine Learning) مجموعه‌ای از روش‌ها و الگوریتم‌هاست که به کامپیوتر اجازه می‌دهد بدون اینکه تمام قوانین یک مسئله به صورت مستقیم برنامه‌نویسی شوند، از داده‌های موجود الگوها را یاد بگیرد و بر اساس آن‌ها برای داده‌های جدید تصمیم‌گیری یا پیش‌بینی انجام دهد.

یکی از مسائل مهم در یادگیری ماشین، رگرسیون (Regression) است. در مسائل رگرسیونی، هدف مدل پیش‌بینی یک مقدار عددی است؛ برای مثال پیش‌بینی قیمت، دما، میزان فروش یا هر مقدار پیوسته دیگر.

دو الگوریتم مهمی که می‌توان برای مسائل رگرسیونی استفاده کرد، Linear Regression و Random Forest Regression هستند. اگرچه هدف هر دو الگوریتم پیش‌بینی یک مقدار عددی است، اما روش رسیدن آن‌ها به این پیش‌بینی کاملاً متفاوت است.

2. Linear Regression

2.1 مفهوم کلی

Linear Regression یا رگرسیون خطی یکی از ساده‌ترین و قدیمی‌ترین الگوریتم‌های یادگیری ماشین است.

ایده اصلی آن این است که بتوان بین متغیرهای ورودی و متغیر خروجی یک رابطه خطی پیدا کرد.

در ساده‌ترین حالت که فقط یک ویژگی ورودی وجود دارد، مدل به دنبال پیدا کردن یک خط مناسب روی نمودار داده‌هاست. معادله این خط به شکل زیر است:

$$\hat{y} = b_0 + b_1x$$

که در این رابطه:

x ویژگی یا ورودی مدل است.

$\hat{y}$ مقدار پیش‌بینی شده است.

b_0 عرض از مبدأ خط است.

b_1 شیب خط است.

بنابراین وظیفه اصلی الگوریتم این است که مقادیر مناسب برای b_0 و b_1 را پیدا کند.

2.2 الگوریتم چگونه خط مناسب را پیدا می‌کند؟

فرض کنیم مجموعه‌ای از داده‌ها در اختیار داریم که هر داده شامل یک ورودی و یک خروجی واقعی است. اگر این داده‌ها را روی یک نمودار رسم کنیم، معمولاً نقاط مختلفی مشاهده می‌شوند که دقیقاً روی یک خط قرار ندارند. Linear Regression تلاش می‌کند خطی پیدا کند که تا حد امکان به تمام این نقاط نزدیک باشد. برای مشخص کردن اینکه یک خط چقدر مناسب است، فاصله بین مقدار واقعی و مقدار پیش‌بینی‌شده محاسبه می‌شود.

این فاصله را می‌توان به صورت زیر نشان داد:

$$\text{Error} = y - \hat{y}$$

که در آن:

y مقدار واقعی است.

$\hat{y}$ مقدار پیش‌بینی‌شده توسط مدل است.

اگر مقدار پیش‌بینی‌شده با مقدار واقعی برابر باشد، خطای مدل صفر خواهد بود، اما چون معمولاً تمام نقاط دقیقاً روی خط قرار ندارند، خطا برای بعضی از داده‌ها مثبت و برای بعضی دیگر منفی خواهد بود. به همین دلیل، الگوریتم معمولاً مربع خطاها را در نظر می‌گیرد تا خطاهای مثبت و منفی یکدیگر را خنثی نکنند.

هدف Linear Regression پیدا کردن خطی است که مجموع مربع این خطاها را حداقل کند. این روش به Least Squares یا «حداقل مربعات» معروف است.

2.3 یک مثال ساده

فرض کنیم داده‌های زیر را داشته باشیم:

X	Y
2	1
4	2
6	3
8	4

مشاهده می‌کنیم که بین X و Y تقریباً یک رابطه مستقیم وجود دارد. در این حالت مدل می‌تواند به رابطه‌ای مانند زیر برسد:

$$\hat{y} = 2x$$

اگر مقدار جدید X برابر 5 باشد، مدل پیش‌بینی می‌کند:

$$\hat{y} = 2 \times 5 = 10$$

بنابراین مدل با یادگیری رابطه موجود در داده‌های قبلی می‌تواند برای داده جدید نیز مقدار خروجی را تخمین بزند.

2.4 رگرسیون خطی با چند ویژگی

Linear Regression فقط به یک متغیر ورودی محدود نمی‌شود. اگر چند ویژگی داشته باشیم، مدل می‌تواند از همه آن‌ها برای پیش‌بینی استفاده کند. در این حالت معادله به شکل زیر خواهد بود:

$$\hat{y} = b_0 + b_1x_1 + b_2x_2 + \dots + b_nx_n$$

برای مثال، اگر سه ویژگی داشته باشیم، مدل تلاش می‌کند ضرایب مربوط به هر سه ویژگی را پیدا کند. هر ضریب نشان می‌دهد که تغییر در آن ویژگی چه تأثیری روی مقدار پیش‌بینی شده دارد، البته با فرض ثابت بودن سایر ویژگی‌ها.

2.5 نقاط قوت و ضعف Linear Regression

مهم‌ترین ویژگی Linear Regression سادگی آن است. ساختار مدل نسبتاً ساده است و می‌توان نحوه تأثیر ویژگی‌ها بر خروجی را تا حد زیادی تفسیر کرد. از طرف دیگر، این الگوریتم برای روابط پیچیده و غیرخطی محدودیت دارد. اگر رابطه واقعی بین ورودی و خروجی شبیه یک خط نباشد، یک مدل خطی ممکن است نتواند الگوی موجود در داده را به خوبی یاد بگیرد.

بنابراین Linear Regression زمانی عملکرد مناسبی دارد که بتوان رابطه بین متغیرها را با یک رابطه خطی تقریب زد.

3. Random Forest

Random Forest یا جنگل تصادفی رویکرد متفاوتی نسبت به Linear Regression دارد. این الگوریتم به جای پیدا کردن یک معادله یا یک خط، از تعداد زیادی Decision Tree یا درخت تصمیم استفاده می‌کند. ایده اصلی Random Forest این است که به جای اینکه به یک مدل تصمیم‌گیری اعتماد کنیم، تعداد زیادی مدل مستقل ایجاد کنیم و سپس نتایج آن‌ها را با یکدیگر ترکیب کنیم. به همین دلیل Random Forest در دسته الگوریتم‌های Ensemble Learning قرار می‌گیرد. کلمه Forest به معنی «جنگل» نیز به همین دلیل استفاده شده است؛ زیرا مدل از تعداد زیادی درخت تشکیل می‌شود.

4. Decision Tree چیست؟

برای درک Random Forest ابتدا باید مفهوم Decision Tree را درک کرد. درخت تصمیم داده‌ها را با استفاده از مجموعه‌ای از سؤال‌ها یا شرط‌ها به قسمت‌های مختلف تقسیم می‌کند. برای مثال، فرض کنیم بخواهیم مقدار یک متغیر عددی را پیش‌بینی کنیم.

درخت ممکن است ابتدا سؤالی مانند "آیا $X < 10$ است" مطرح کند:

اگر پاسخ بله باشد، داده به یک شاخه و اگر پاسخ خیر باشد، به شاخه دیگری می‌رود. سپس در هر شاخه می‌توان شرط‌های دیگری قرار داد. این فرآیند چندین بار تکرار می‌شود و در نهایت داده به یک نقطه پایانی یا Leaf می‌رسد. در مسائل رگرسیونی، مقدار موجود در Leaf معمولاً برای تولید پیش‌بینی عددی استفاده می‌شود.

5. Random Forest چگونه کار می‌کند؟

Random Forest با ساخت تعداد زیادی Decision Tree شروع می‌شود. اما نکته مهم این است که همه درخت‌ها دقیقاً یکسان ساخته نمی‌شوند. برای ایجاد تنوع بین درخت‌ها، الگوریتم از دو نوع تصادفی‌سازی استفاده می‌کند.

5.1 انتخاب تصادفی داده‌ها

برای ساخت هر درخت، نمونه‌هایی از داده‌های آموزشی به صورت تصادفی انتخاب می‌شوند. در نتیجه هر درخت بخشی متفاوت از داده‌ها را مشاهده می‌کند. به این روش معمولاً Bootstrap Sampling گفته می‌شود. بنابراین درخت اول ممکن است بیشتر روی یک مجموعه از نمونه‌ها آموزش ببیند و درخت دوم مجموعه متفاوتی از نمونه‌ها را دریافت کند.

5.2 انتخاب تصادفی ویژگی‌ها

Random Forest علاوه بر انتخاب تصادفی داده‌ها، هنگام ایجاد هر تقسیم در درخت، تنها بخشی از ویژگی‌ها را به صورت تصادفی بررسی می‌کند. فرض کنیم یک مجموعه داده 10 ویژگی داشته باشد، در یک مرحله از ساخت یک درخت، ممکن است فقط چند ویژگی از این 10 ویژگی برای انتخاب بهترین تقسیم در نظر گرفته شوند. در مرحله دیگری ممکن است مجموعه متفاوتی از ویژگی‌ها انتخاب شود. این کار باعث می‌شود درخت‌ها ساختارهای متفاوتی پیدا کنند.

6. ساخت هر درخت

پس از انتخاب داده‌ها و ویژگی‌ها، هر درخت به صورت یک Decision Tree معمولی ساخته می‌شود. درخت تلاش می‌کند داده‌ها را به گونه‌ای تقسیم کند که نمونه‌های موجود در هر بخش تا حد امکان رفتار مشابهی داشته باشند. در مسائل رگرسیونی، یکی از معیارهای رایج برای ارزیابی کیفیت تقسیم‌ها، کاهش میزان پراکندگی یا خطا در گروه‌های ایجادشده است. درخت این تقسیم‌ها را به صورت متوالی انجام می‌دهد تا به نقاط پایانی برسد. در نهایت هر درخت می‌تواند برای یک ورودی جدید، یک مقدار عددی را پیش‌بینی کند.

7. ترکیب نتایج درخت‌ها

بعد از اینکه تمام درخت‌ها ساخته شدند، هنگام پیش‌بینی یک داده جدید، داده به تمام درخت‌های موجود در جنگل داده می‌شود و هر درخت یک پیش‌بینی مستقل ارائه می‌دهد.

برای مثال فرض کنیم پنج درخت داشته باشیم و نتایج آن‌ها به صورت زیر باشد:

درخت اول: 100، درخت دوم: 105، درخت سوم: 98، درخت چهارم: 102، درخت پنجم: 110

در Random Forest Regression، پیش‌بینی نهایی معمولاً از میانگین خروجی درخت‌ها به دست می‌آید:

$$\text{Prediction} = (100 + 105 + 98 + 102 + 110) / 5$$

بنابراین:

$$\text{Prediction} = 103$$

در نتیجه به جای اینکه تنها به پیش‌بینی یک درخت اعتماد شود، نتیجه چندین درخت با یکدیگر ترکیب می‌شود.

8. چرا Random Forest از چند درخت استفاده می‌کند؟

یک Decision Tree به تنهایی می‌تواند بیش از حد به داده‌های آموزشی وابسته شود. به این مسئله Overfitting گفته می‌شود. برای مثال ممکن است یک درخت جزئیات بسیار خاص داده‌های آموزشی را یاد بگیرد، اما هنگام مواجه شدن با داده‌های جدید عملکرد مناسبی نداشته باشد. Random Forest با ایجاد تعداد زیادی درخت متفاوت و ترکیب نتایج آن‌ها تلاش می‌کند این مشکل را کاهش دهد.

اگر یک درخت به دلیل ویژگی‌های خاص داده‌های آموزشی پیش‌بینی نامناسبی انجام دهد، تأثیر آن در نتیجه نهایی با ترکیب شدن پیش‌بینی تعداد زیادی درخت کاهش پیدا می‌کند. بنابراین قدرت Random Forest فقط در «زیاد بودن تعداد درخت‌ها» نیست؛ بلکه تنوع بین درخت‌ها و ترکیب نتایج آن‌ها بخش مهمی از عملکرد الگوریتم را تشکیل می‌دهد.

9. تفاوت اساسی Linear Regression و Random Forest

تفاوت اصلی این دو الگوریتم در نحوه نمایش رابطه بین ورودی و خروجی است. Linear Regression فرض می‌کند که می‌توان رابطه موجود در داده را با یک رابطه خطی تقریب زد. در مقابل، Random Forest برای پیدا کردن یک معادله مشخص تلاش نمی‌کند. این الگوریتم با تقسیم کردن فضای داده به قسمت‌های مختلف و استفاده از تعداد زیادی درخت تصمیم، الگوهای موجود در داده را یاد می‌گیرد. به همین دلیل Random Forest می‌تواند روابط غیرخطی و پیچیده‌تری را مدل کند.

به صورت خلاصه:

Linear Regression → پیدا کردن بهترین رابطه خطی

Random Forest → ساخت تعداد زیادی درخت تصمیم و ترکیب پیش‌بینی آن‌ها

10. جمع‌بندی

Linear Regression و Random Forest هر دو برای حل مسائل رگرسیونی قابل استفاده هستند، اما از دو دیدگاه کاملاً متفاوت به مسئله نگاه می‌کنند. در Linear Regression، هدف پیدا کردن ضرایبی است که یک رابطه خطی مناسب بین ورودی‌ها و خروجی ایجاد کنند. الگوریتم با بررسی خطاهای پیش‌بینی، ضرایبی را انتخاب می‌کند که مجموع خطاهای مربعی را حداقل کنند. در Random Forest، به جای ساخت یک رابطه ریاضی ساده، تعداد زیادی Decision Tree ساخته می‌شود. هر درخت با استفاده از نمونه‌ها و ویژگی‌های انتخاب‌شده به صورت تصادفی آموزش می‌بیند و برای داده جدید یک پیش‌بینی ارائه می‌دهد. در نهایت پیش‌بینی درخت‌ها با یکدیگر ترکیب شده و برای مسائل رگرسیونی معمولاً میانگین خروجی آن‌ها به عنوان پیش‌بینی نهایی انتخاب می‌شود.

در نتیجه، می‌توان گفت Linear Regression یک مدل ساده و مبتنی بر رابطه خطی است، در حالی که Random Forest یک مدل Ensemble مبتنی بر مجموعه‌ای از درخت‌های تصمیم است که می‌تواند روابط پیچیده‌تر و غیرخطی را نیز یاد بگیرد.