

به نام خداوند بخشنده مهربان


1. هدف Feature Engineering

داده‌ی خامی که از منابع مختلف قیمت نقره دریافت می‌شود، تنها شامل مقدار قیمت و زمان ثبت آن است. این داده به تنهایی اطلاعات کافی برای استخراج الگوهای زمانی موردنیاز مدل‌های پیش‌بینی را در اختیار مدل قرار نمی‌دهد. بنابراین قبل از آموزش مدل، داده‌ی خام به مجموعه‌ای از ویژگی‌های عددی (Features) تبدیل می‌شود که بتوانند رفتار گذشته‌ی قیمت هر منبع را به مدل منتقل کنند.

در این پروژه، پیش‌بینی برای هر منبع به صورت مستقل انجام می‌شود. بنابراین داده‌های TGJU، Silfam و NogrehSea با یکدیگر ادغام نمی‌شوند و هر منبع DataFrame و مجموعه ویژگی‌های مربوط به خودش را دارد.

2. جریان آماده‌سازی داده

فرآیند آماده‌سازی داده به دو مرحله‌ی اصلی تقسیم شده است:



این تفکیک باعث شده مسئولیت استخراج داده از دیتابیس از مسئولیت ساخت ویژگی‌ها جدا باشد.

Data Loader:

وظیفه‌ی Data Loader دریافت داده‌های خام قیمت از دیتابیس است. برای هر منبع، داده‌هایی مانند موارد زیر در اختیار قرار می‌گیرد:

price

fetch_at

created_at

و سپس داده‌ها بر اساس منبع در DataFrame‌های جداگانه قرار می‌گیرند.

Feature Preparation:

تابع prepare_features روی DataFrame مربوط به یک منبع اجرا می‌شود و ویژگی‌های موردنیاز همان منبع را تولید می‌کند. به این ترتیب، Feature Preparation هیچ وابستگی مستقیمی به نحوه‌ی دریافت داده از PostgreSQL ندارد.

3. ویژگی‌های مورد استفاده

در این پروژه سه گروه اصلی Feature ساخته می‌شود:

Lag Features 3.1

Lag نشان‌دهنده‌ی قیمت‌های گذشته‌ی همان منبع است. برای مثال:

lag_1 = قیمت قبلی

lag_2 = قیمت دو رکورد قبل

lag_3 = قیمت سه رکورد قبل

دلیل استفاده از Lag این است که قیمت فعلی معمولاً می‌تواند تحت تأثیر مقادیر قبلی خود قرار داشته باشد. مثلاً اگر داده‌ها به شکل زیر باشند:

زمان	قیمت
10:00	400000
11:00	401000
12:00	402000
13:00	403000

برای رکورد ساعت 13:

$$\text{lag_1} = 402000$$

$$\text{lag_2} = 401000$$

$$\text{lag_3} = 400000$$

بنابراین مدل به جای مشاهده‌ی تنها قیمت فعلی، بخشی از تاریخچه‌ی اخیر قیمت را نیز دریافت می‌کند.

4. Moving Average

Moving Average یا میانگین متحرک برای کاهش نوسانات کوتاه مدت و نمایش روند کلی تر قیمت استفاده می‌شود. در این پروژه دو میانگین متحرک استفاده می‌شود:

MA_3 , MA_5

MA_3 میانگین سه قیمت اخیر را محاسبه می‌کند و MA_5 میانگین پنج قیمت اخیر را محاسبه می‌کند:

$$\text{MA}_3 = (P_t + P_{t-1} + P_{t-2}) / 3$$

$$\text{MA}_5 = (P_t + P_{t-1} + P_{t-2} + P_{t-3} + P_{t-4}) / 5$$

استفاده از دو Window متفاوت باعث می‌شود مدل بتواند هم رفتار کوتاه‌مدت و هم روند کمی بلندمدت‌تر قیمت را مشاهده کند. در واقع:

MA_3 : حساس‌تر به تغییرات اخیر

MA_5 : روند را کمی هموارتر نشان می‌دهد

5. Price Change

ویژگی price_change درصد تغییر قیمت نسبت به رکورد قبلی را نشان می‌دهد.

فرمول آن:

$$\text{price_change} = (P_t - P_{t-1}) / P_{t-1}$$

مثلاً اگر قیمت از 400000 به 404000 برسد:

$$\text{price_change} = (404000 - 400000) / 400000 = 0.01$$

یعنی قیمت نسبت به رکورد قبلی ۱٪ افزایش داشته است.

دلیل استفاده از این Feature این است که مقدار مطلق قیمت همیشه به تنهایی بیانگر شدت حرکت بازار نیست. درصد تغییر، جهت و اندازه‌ی حرکت اخیر قیمت را به شکل قابل استفاده‌تری در اختیار مدل قرار می‌دهد.

6. Target یا مقدار مورد پیش‌بینی

هدف مدل، پیش‌بینی قیمت رکورد بعدی است. بنابراین از ویژگی next_price به عنوان Target استفاده می‌شود:

$$\text{next_price} = P_{t+1}$$

برای مثال:

Price	Lag 1	MA 3	Price Change	Next Price
400000	...	...	...	401000
401000	400000	...	...	402000
402000	401000	401000	...	403000

مدل Features مربوط به زمان t را دریافت می‌کند و تلاش می‌کند مقدار قیمت در زمان t+1 را پیش‌بینی کند.

7. چرا این Features انتخاب شدند؟

انتخاب ویژگی‌ها بر اساس این ایده انجام شده که مدل باید سه نوع اطلاعات را درباره‌ی قیمت در اختیار داشته باشد:

اطلاعاتی که منتقل می‌کند	Feature
آخرین قیمت	lag_1
قیمت کمی قدیمی‌تر	lag_2
بخشی از روند اخیر	lag_3
روند کوتاه‌مدت	ma_3
روند هموارتر	ma_5
شدت و جهت تغییر اخیر	price_change

بنابراین مجموعه ویژگی‌ها ترکیبی از مقدار قیمت، تاریخچه‌ی اخیر، روند و میزان تغییرات قیمت است.

8. نکته مهم درباره‌ی منابع داده

یکی از تصمیمات طراحی این پروژه این است که قیمت منابع مختلف مستقیماً با یکدیگر Merge نمی‌شوند.

یعنی:

TGJU → Features → Model → TGJU Prediction

Silfam → Features → Model → Silfam Prediction

NoghrehSea → Features → Model → NoghrehSea Prediction

این تصمیم به این دلیل گرفته شده که هدف سیستم، پیش‌بینی قیمت منتشرشده توسط هر منبع به‌صورت مستقل است، نه تولید یک قیمت میانگین برای بازار. در نتیجه، تفاوت رفتاری منابع نیز حفظ می‌شود و مدل هر منبع بر اساس تاریخچه‌ی همان منبع آموزش داده می‌شود.

9. حذف رکوردهای ابتدایی

ساخت بعضی Features به اطلاعات قبلی نیاز دارد. مثلاً برای محاسبه‌ی lag_3 حداقل سه رکورد لازم است و برای MA_5 حداقل پنج رکورد. بنابراین در ابتدای DataFrame تعدادی مقدار NaN ایجاد می‌شود. این رکوردها قبل از استفاده در آموزش مدل حذف می‌شوند تا داده‌ی ورودی مدل شامل مقادیر ناقص نباشد.

در نهایت، داده‌ی خام هر منبع به یک Dataset ساختاریافته تبدیل می‌شود که شامل:

Historical Prices

+

Lag Features

+

Moving Averages

+

Price Change

↓

Prediction Features

+

Next Price

↓

Training Dataset

این Dataset سپس به مرحله‌ی Training منتقل می‌شود تا مدل‌های Linear Regression و Random Forest بتوانند بر اساس رفتار تاریخی همان منبع آموزش ببینند.