

به نام خداوند بخشنده مهربان

1. هدف مرحله آموزش مدل

پس از آماده‌سازی Dataset، مرحله بعد آموزش مدل‌های یادگیری ماشین است. هدف این مرحله ایجاد مدلی است که بتواند با استفاده از اطلاعات تاریخی موجود، قیمت بعدی نقره را برای هر منبع پیش‌بینی کند. در این پروژه دو الگوریتم برای این منظور استفاده شده است:


Linear Regression

Random Forest Regressor

استفاده از دو الگوریتم متفاوت این امکان را فراهم می‌کند که عملکرد یک مدل خطی با یک مدل مبتنی بر درخت‌های تصمیم مقایسه شود.

2. جریان کلی آموزش

فرآیند Training به شکل زیر انجام می‌شود:



مرحله Feature Preparation در مستند جداگانه توضیح داده شده و در این بخش صرفاً خروجی آن به عنوان ورودی فرآیند Training در نظر گرفته می‌شود.

3. تفکیک داده‌های آموزش و آزمون

برای ارزیابی مدل، Dataset به دو بخش تقسیم می‌شود:

- ۸۰٪ ابتدایی داده‌ها برای آموزش

- ۲۰٪ انتهایی داده‌ها برای آزمون

تقسیم داده به صورت ترتیبی انجام می‌شود و داده‌ها قبل از تقسیم Shuffle نمی‌شوند. برای مثال اگر داده‌ها به ترتیب زمانی زیر باشند:

T1 T2 T3 T4 T5 T6 T7 T8 T9 T10

تقسیم به شکل زیر خواهد بود:

Training : T1 T2 T3 T4 T5 T6 T7 T8

Testing : T9 T10

دلیل استفاده از تقسیم زمانی

داده قیمت نقره ماهیت زمانی دارد. مدل در زمان واقعی تنها به اطلاعات گذشته دسترسی دارد و نباید در زمان آموزش اطلاعات مربوط به آینده را مشاهده کند. اگر داده‌ها به صورت تصادفی Shuffle شوند، ممکن است رکوردهای مربوط به آینده وارد مجموعه آموزش شوند و رکوردهای قدیمی‌تر در مجموعه آزمون قرار بگیرند. این مسئله باعث ایجاد Data Leakage و در نتیجه ارزیابی غیرواقعی مدل خواهد شد. بنابراین ترتیب زمانی داده‌ها در فرآیند Training حفظ می‌شود.

4. متغیرهای ورودی و هدف

پس از آماده‌سازی Dataset، ویژگی‌های تعریف‌شده به عنوان متغیرهای ورودی "X" و قیمت بعدی به عنوان متغیر هدف "y" استفاده می‌شود. به صورت مفهومی:

X = Historical Price Information

y = Next Price

در نتیجه مدل تلاش می‌کند تابعی را یاد بگیرد که رابطه بین اطلاعات موجود در زمان فعلی و قیمت رکورد بعدی را تخمین بزند.

5. مدل Linear Regression

Linear Regression یک مدل آماری و یادگیری ماشین است که رابطه بین متغیرهای ورودی و متغیر هدف را با یک تابع خطی تخمین می‌زند.

به شکل ساده، مدل تلاش می‌کند رابطه‌ای مشابه زیر پیدا کند:

$$y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n$$

که در آن

- "y" قیمت پیش‌بینی شده است.

- "X" ها ویژگی‌های ورودی هستند.


- "β" ها ضرایبی هستند که مدل در مرحله آموزش یاد می‌گیرد.

- "β0" مقدار ثابت مدل است.

در این پروژه، ضرایب بر اساس داده‌های تاریخی آموزش محاسبه می‌شوند. Linear Regression ساده و قابل تفسیر است و می‌تواند به عنوان یک Baseline Model مناسب استفاده شود. اما رابطه واقعی بین قیمت و ویژگی‌های آن ممکن است کاملاً خطی نباشد. در چنین شرایطی، توان مدل برای نمایش روابط پیچیده محدود خواهد شد.

6. مدل Random Forest Regressor

Random Forest Regressor یک مدل Ensemble است که از مجموعه‌ای از Decision Tree ها تشکیل می‌شود. به جای استفاده از یک درخت تصمیم، چندین درخت ساخته می‌شوند و خروجی آن‌ها برای تولید پیش‌بینی نهایی ترکیب می‌شود. فرآیند کلی:



در مسئله Regression، خروجی نهایی Random Forest از ترکیب پیش‌بینی درخت‌ها به دست می‌آید. در پروژه برای ساخت مدل از تنظیم زیر استفاده شده است:

`n_estimators = 100`

`random_state = 42`

`:n_estimators`

تعداد درخت‌های موجود در Forest را مشخص می‌کند. در این پروژه ۱۰۰ درخت استفاده شده است تا مدل بتواند از چندین ساختار تصمیم مختلف برای تولید پیش‌بینی استفاده کند.

`:random_state`

برای کنترل بخش تصادفی فرآیند آموزش استفاده می‌شود. ثابت بودن این مقدار باعث می‌شود اجرای مجدد آموزش با شرایط یکسان، نتیجه قابل تکرارتری داشته باشد.

Random Forest می‌تواند روابط غیرخطی و تعامل بین ویژگی‌ها را بهتر از یک مدل خطی نمایش دهد. اما در مقایسه با Linear Regression تفسیر مستقیم رابطه بین هر Feature و خروجی دشوارتر است و مدل پیچیدگی بیشتری دارد.

7. دلیل استفاده از دو الگوریتم

استفاده از تنها یک الگوریتم مشخص نمی‌کند که آن مدل برای Dataset پروژه بهترین انتخاب است. به همین دلیل دو مدل با ماهیت متفاوت استفاده شده‌اند. Linear Regression یک نقطه مقایسه ساده و قابل تفسیر ایجاد می‌کند، در حالی که Random Forest امکان مدل‌سازی روابط غیرخطی را فراهم می‌کند. در نتیجه عملکرد هر دو مدل روی یک مجموعه آزمون یکسان اندازه‌گیری و مقایسه می‌شود.

8. ارزیابی مدل‌ها

پس از آموزش، مدل‌ها روی داده‌های Test اجرا می‌شوند. مقادیر پیش‌بینی‌شده با مقادیر واقعی مقایسه می‌شوند تا میزان خطای هر مدل مشخص شود. در این پروژه دو معیار MAE و RMSE استفاده شده است:

8.1 Mean Absolute Error

MAE میانگین مقدار مطلق اختلاف بین مقدار واقعی و مقدار پیش‌بینی‌شده است.

$$MAE = (1/n) \sum |y_i - \hat{y}_i|$$

که در آن:

- y_i مقدار واقعی

- $\hat{y}_i$ مقدار پیش‌بینی‌شده

- n تعداد نمونه‌ها

مزیت MAE این است که مقدار خطا مستقیماً در واحد Target بیان می‌شود. برای مثال اگر:

MAE = 5000 باشد، می‌توان آن را به صورت میانگین حدود ۵۰۰۰ واحد خطا در پیش‌بینی تفسیر کرد.

8.2. Root Mean Squared Error

RMSE ریشه میانگین مربعات خطاها است

$$RMSE = \sqrt{[(1/n) \sum (y_i - \hat{y}_i)^2]}$$

به دلیل وجود توان دوم، خطاهای بزرگ‌تر تأثیر بیشتری روی مقدار RMSE دارند. بنابراین RMSE برای بررسی این موضوع مفید است که آیا مدل در برخی نمونه‌ها خطاهای بسیار بزرگی ایجاد می‌کند یا خیر.

8.3. مقایسه مدل‌ها

هر دو مدل روی یک Test Set یکسان ارزیابی می‌شوند. به‌طور کلی:

MAE کمتر → خطای مطلق کمتر

RMSE کمتر → خطای بزرگ کمتر

بنابراین برای مقایسه دو مدل، مدلی که معیارهای خطای پایین‌تری داشته باشد عملکرد بهتری روی داده آزمون نشان می‌دهد. با این حال، معیارهای ارزیابی فقط عملکرد مدل روی همین Dataset را نشان می‌دهند و به‌تنهایی تضمین نمی‌کنند که مدل در تمام شرایط آینده نیز عملکرد مشابهی داشته باشد.

9. ذخیره مدل

پس از پایان آموزش و ارزیابی، مدل‌ها در فایل ذخیره می‌شوند تا در زمان Prediction مجدداً آموزش داده نشوند. برای این کار از کتابخانه "joblib" استفاده شده است.

ساختار فایل‌های خروجی:

/ml_models

linear_regression.pkl —┐

random_forest.pkl —┘

فایل‌های "pkl." شامل مدل آموزش‌دیده هستند. در زمان پیش‌بینی، سرویس Prediction فایل مدل مربوطه را با "joblib.load()" بارگذاری کرده و از آن برای تولید Prediction استفاده می‌کند. این روش باعث می‌شود فرآیند Training از فرآیند Prediction جدا باشد.

10. مدیریت خطا در Training

در فرآیند آموزش چند وضعیت می‌تواند باعث شکست عملیات شود، از جمله:

- نبود داده در دیتابیس

- ناکافی بودن داده برای ایجاد Dataset معتبر

- وجود مشکل در آماده‌سازی Features

- شکست فرآیند آموزش

- مشکل در ایجاد مسیر ذخیره مدل

- خطا هنگام ذخیره فایل مدل

در صورت نبود داده، فرآیند Training نباید با یک Dataset خالی ادامه پیدا کند و خطای مناسب ایجاد می‌شود. همچنین مسیر ذخیره مدل در صورت نیاز به‌صورت خودکار ایجاد می‌شود تا ذخیره فایل‌ها به دلیل نبود پوشه مقصد با خطا مواجه نشود.

11. تکرارپذیری فرآیند

برای Random Forest مقدار "random_state" مشخص شده است. این کار باعث می‌شود بخش تصادفی الگوریتم کنترل شود و اجرای مجدد فرآیند Training با Dataset و تنظیمات یکسان، قابل تکرارتر باشد. این ویژگی در زمان تست و مقایسه نسخه‌های مختلف مدل اهمیت دارد، زیرا تغییرات عملکرد را می‌توان با اطمینان بیشتری به تغییرات داده یا تنظیمات مدل نسبت داد.

12. محدودیت‌های فعلی

پیاده‌سازی فعلی یک روش نسبتاً ساده برای پیش‌بینی سری زمانی ارائه می‌کند و محدودیت‌هایی دارد. از جمله:

- تنها دو الگوریتم مورد بررسی قرار گرفته‌اند.

- تنظیم پارامترهای مدل‌ها به‌صورت گسترده انجام نشده است.

- ارزیابی با یک تقسیم ثابت ۲۰/۸۰ انجام می‌شود.


- معیارهای ارزیابی محدود به MAE و RMSE هستند.

- متغیرهای خارجی مانند نرخ ارز، اخبار بازار یا سایر شاخص‌های اقتصادی وارد مدل نشده‌اند.

این موارد به معنی نادرست بودن مدل نیستند، بلکه محدوده فعلی پیاده‌سازی را مشخص می‌کنند و می‌توانند در نسخه‌های بعدی توسعه داده شوند.

13. خروجی مرحله Training

در پایان فرآیند، برای هر مدل یک مدل آموزش‌دیده و ارزیابی‌شده در اختیار سیستم قرار می‌گیرد. خروجی کلی مرحله:



این فایل‌های مدل در مرحله بعد توسط Prediction Service بارگذاری می‌شوند و برای تولید پیش‌بینی مورد استفاده قرار می‌گیرند.